# SCRIPT UTILIZZATI

## Sentence_split_versione1(punteggiatura).py

```
import os
import re

cartella_input = "data/raw"
cartella_output = "output/sentence_split_versione1"

if not os.path.exists(cartella_output):
    os.makedirs(cartella_output)

lista_file = os.listdir(cartella_input)

for nome_file in lista_file:
    if nome_file.endswith(".sent_split"):

        percorso_input = os.path.join(cartella_input, nome_file)
        percorso_output = os.path.join(cartella_output, nome_file)

        file_input = open(percorso_input, "r", encoding="utf-8")
        testo = file_input.read()
        file_input.close()

        testo = testo.replace("<EOS>", " ")

        pezzi = re.split(r'(?<=[.!?])\s+', testo)

        frasi_finali = []

        for pezzo in pezzi:
            pezzo_pulito = pezzo.strip()

            if pezzo_pulito != "":
                frasi_finali.append(pezzo_pulito)

        file_output = open(percorso_output, "w", encoding="utf-8")

        for frase in frasi_finali:
            file_output.write(frase + "\n")

        file_output.close()

        print("Creato file:", nome_file)

print("Ho finito.")
```

## Valutazione_versione1.py

```
import os

cartella_gold = "data/processed"
cartella_pred = "output/sentence_split_versione1"

def leggi_frasi(percorso):
    file = open(percorso, "r", encoding="utf-8")
    righe = file.readlines()
    file.close()

    frasi = []
    for riga in righe:
        riga = riga.strip()
        if riga != "":
            frasi.append(riga)

    return frasi

def divisione_sicura(a, b):
    if b == 0:
        return 0.0
    return a / b

lista_file = os.listdir(cartella_gold)

tutti_risultati = []

for nome_file in lista_file:
    if nome_file.endswith(".sent_split"):

        percorso_gold = os.path.join(cartella_gold, nome_file)
        percorso_pred = os.path.join(cartella_pred, nome_file)

        if not os.path.exists(percorso_pred):
            print("Manca file predetto:", nome_file)
            continue

        frasi_gold = leggi_frasi(percorso_gold)
        frasi_pred = leggi_frasi(percorso_pred)

        set_gold = set(frasi_gold)
        set_pred = set(frasi_pred)

        veri_positivi = len(set_gold.intersection(set_pred))
        tot_pred = len(set_pred)
        tot_gold = len(set_gold)

        precision = divisione_sicura(veri_positivi, tot_pred)
        recall = divisione_sicura(veri_positivi, tot_gold)

        if precision + recall == 0:
            f1 = 0.0
        else:
```

```
        f1 = 2 * precision * recall / (precision + recall)

    risultato = {
        "precision": precision,
        "recall": recall,
        "f1": f1
    }

    tutti_risultati.append(risultato)

    print("\nFile:", nome_file)
    print("Frasi gold     :", tot_gold)
    print("Frasi predette :", tot_pred)
    print("Match esatti   :", veri_positivi)
    print("Precision      :", round(precision, 4))
    print("Recall         :", round(recall, 4))
    print("F1             :", round(f1, 4))

# media finale
if len(tutti_risultati) > 0:
    somma_precision = 0
    somma_recall = 0
    somma_f1 = 0

    for r in tutti_risultati:
        somma_precision += r["precision"]
        somma_recall += r["recall"]
        somma_f1 += r["f1"]

    media_precision = somma_precision / len(tutti_risultati)
    media_recall = somma_recall / len(tutti_risultati)
    media_f1 = somma_f1 / len(tutti_risultati)

    print("\n===== MEDIA COMPLESSIVA =====")
    print("Precision media:", round(media_precision, 4))
    print("Recall media   :", round(media_recall, 4))
    print("F1 media       :", round(media_f1, 4))
else:
    print("Nessun file valutato.")
```

## Debug_versione1.py

```
import os

cartella_gold = "data/processed"
cartella_pred = "output/sentence_split_versione1"

def leggi_frasi(percorso):
    file = open(percorso, "r", encoding="utf-8")
    righe = file.readlines()
    file.close()
```

```
    frasi = []

    for riga in righe:
        riga = riga.strip()
        if riga != "":
            frasi.append(riga)

    return frasi

lista_file = os.listdir(cartella_gold)

for nome_file in lista_file:
    if nome_file.endswith(".sent_split"):

        percorso_gold = os.path.join(cartella_gold, nome_file)
        percorso_pred = os.path.join(cartella_pred, nome_file)

        if not os.path.exists(percorso_pred):
            print("Manca file predetto:", nome_file)
            continue

        frasi_gold = leggi_frasi(percorso_gold)
        frasi_pred = leggi_frasi(percorso_pred)

        set_gold = set(frasi_gold)
        set_pred = set(frasi_pred)

        frasi_mancate = set_gold - set_pred

        print("\n==============================")
        print("FILE:", nome_file)
        print("==============================")

        print("\nFrasi NON trovate dalla Versione 1:")

        if len(frasi_mancate) == 0:
            print("Nessuna")
        else:
            contatore = 1

            for frase in frasi_mancate:
                print(str(contatore) + ".", frase)
                contatore = contatore + 1
```

## Sentence_split_versione2(punteggiatura_estesa).py

```
import os
import re

cartella_input = "data/raw"
cartella_output = "output/sentence_split_versione2"

if not os.path.exists(cartella_output):
```

```
    os.makedirs(cartella_output)

lista_file = os.listdir(cartella_input)

for nome_file in lista_file:
    if nome_file.endswith(".sent_split"):

        percorso_input = os.path.join(cartella_input, nome_file)
        percorso_output = os.path.join(cartella_output, nome_file)

        file_input = open(percorso_input, "r", encoding="utf-8")
        testo = file_input.read()
        file_input.close()

        testo = testo.replace("<EOS>", " ")

        pezzi = re.split(r'(?<=[.!?:;])\s+', testo)

        frasi_finali = []

        for pezzo in pezzi:
            pezzo_pulito = pezzo.strip()

            if pezzo_pulito != "":
                frasi_finali.append(pezzo_pulito)

        file_output = open(percorso_output, "w", encoding="utf-8")

        for frase in frasi_finali:
            file_output.write(frase + "\n")

        file_output.close()

        print("Creato file:", nome_file)

print("Ho finito.")
```

## Valutazione_versione2.py

```
import os

cartella_gold = "data/processed"
cartella_pred = "output/sentence_split_versione2"

def leggi_frasi(percorso):
    file = open(percorso, "r", encoding="utf-8")
    righe = file.readlines()
    file.close()

    frasi = []
    for riga in righe:
        riga = riga.strip()
```

```
        if riga != "":
            frasi.append(riga)

    return frasi

def divisione_sicura(a, b):
    if b == 0:
        return 0.0
    return a / b

lista_file = os.listdir(cartella_gold)

tutti_risultati = []

for nome_file in lista_file:
    if nome_file.endswith(".sent_split"):

        percorso_gold = os.path.join(cartella_gold, nome_file)
        percorso_pred = os.path.join(cartella_pred, nome_file)

        if not os.path.exists(percorso_pred):
            print("Manca file predetto:", nome_file)
            continue

        frasi_gold = leggi_frasi(percorso_gold)
        frasi_pred = leggi_frasi(percorso_pred)

        set_gold = set(frasi_gold)
        set_pred = set(frasi_pred)

        veri_positivi = len(set_gold.intersection(set_pred))
        tot_pred = len(set_pred)
        tot_gold = len(set_gold)

        precision = divisione_sicura(veri_positivi, tot_pred)
        recall = divisione_sicura(veri_positivi, tot_gold)

        if precision + recall == 0:
            f1 = 0.0
        else:
            f1 = 2 * precision * recall / (precision + recall)

        risultato = {
            "precision": precision,
            "recall": recall,
            "f1": f1
        }

        tutti_risultati.append(risultato)

        print("\nFile:", nome_file)
        print("Frasi gold     :", tot_gold)
        print("Frasi predette :", tot_pred)
        print("Match esatti   :", veri_positivi)
        print("Precision      :", round(precision, 4))
```

```
        print("Recall        :", round(recall, 4))
        print("F1            :", round(f1, 4))

if len(tutti_risultati) > 0:
    somma_precision = 0
    somma_recall = 0
    somma_f1 = 0

    for r in tutti_risultati:
        somma_precision += r["precision"]
        somma_recall += r["recall"]
        somma_f1 += r["f1"]

    media_precision = somma_precision / len(tutti_risultati)
    media_recall = somma_recall / len(tutti_risultati)
    media_f1 = somma_f1 / len(tutti_risultati)

    print("\n===== MEDIA COMPLESSIVA =====")
    print("Precision media:", round(media_precision, 4))
    print("Recall media   :", round(media_recall, 4))
    print("F1 media       :", round(media_f1, 4))
else:
    print("Nessun file valutato.")
```

## Confronto_errori_versione1_versione2.py

```
import os

cartella_gold = "data/processed"
cartella_v1 = "output/sentence_split_versione1"
cartella_v2 = "output/sentence_split_versione2"

def leggi_frasi(percorso):
    file = open(percorso, "r", encoding="utf-8")
    righe = file.readlines()
    file.close()

    frasi = []

    for riga in righe:
        riga = riga.strip()
        if riga != "":
            frasi.append(riga)

    return frasi

lista_file = os.listdir(cartella_gold)

for nome_file in lista_file:
    if nome_file.endswith(".sent_split"):

        percorso_gold = os.path.join(cartella_gold, nome_file)
```

```
    percorso_v1 = os.path.join(cartella_v1, nome_file)
    percorso_v2 = os.path.join(cartella_v2, nome_file)

    if not os.path.exists(percorso_v1):
        print("Manca file versione1:", nome_file)
        continue

    if not os.path.exists(percorso_v2):
        print("Manca file versione2:", nome_file)
        continue

    frasi_gold = leggi_frasi(percorso_gold)
    frasi_v1 = leggi_frasi(percorso_v1)
    frasi_v2 = leggi_frasi(percorso_v2)

    set_gold = set(frasi_gold)
    set_v1 = set(frasi_v1)
    set_v2 = set(frasi_v2)

    mancate_v1 = set_gold - set_v1
    mancate_v2 = set_gold - set_v2

    print("\n==============================")
    print("FILE:", nome_file)
    print("==============================")

    print("\nFrasi NON matchate da VERSIONE 1:")
    if len(mancate_v1) == 0:
        print("Nessuna")
    else:
        contatore = 1
        for frase in mancate_v1:
            print(str(contatore) + ".", frase)
            contatore = contatore + 1

    print("\nFrasi NON matchate da VERSIONE 2:")
    if len(mancate_v2) == 0:
        print("Nessuna")
    else:
        contatore = 1
        for frase in mancate_v2:
            print(str(contatore) + ".", frase)
            contatore = contatore + 1
```

## Clean_dataset.py

```
import os

cartella_input = "data/raw"
cartella_output = "data/processed"

if not os.path.exists(cartella_output):
```

```
    os.makedirs(cartella_output)

lista_file = os.listdir(cartella_input)

for nome_file in lista_file:
    if nome_file.endswith(".sent_split"):

        percorso_input = os.path.join(cartella_input, nome_file)
        percorso_output = os.path.join(cartella_output, nome_file)

        file_input = open(percorso_input, "r", encoding="utf-8")
        testo = file_input.read()
        file_input.close()

        testo = testo.replace("<EOS>", "\n")

        righe = testo.split("\n")
        frasi_pulite = []

        for riga in righe:
            riga = riga.strip()
            if riga != "":
                frasi_pulite.append(riga)

        file_output = open(percorso_output, "w", encoding="utf-8")

        for frase in frasi_pulite:
            file_output.write(frase + "\n")

        file_output.close()

        print("Creato file gold:", nome_file)

print("Pulizia dataset completata.")
```